

Optimisation convexe non-lisse

I / Motivations et rappels

1) Un problème d'optimisation "fréquent"

$$\min_{x \in \mathbb{R}^n} h(x) = f(x) + g(x)$$

avec $f: \mathbb{R}^n \rightarrow \mathbb{R}$ lisse à savoir un gradient lipschitzien :

$$\exists L > 0 \text{ tq } \forall (x, y) \in \mathbb{R}^n \times \mathbb{R}^n \quad \|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|$$

$g: \mathbb{R}^n \rightarrow \mathbb{R}$ convexe potentiellement non-lisse.

- ex:
- i) $g = 0$ optimisation lisse non convexe
 - ii) $g(x) = \lambda \|x\|_1$ avec $\lambda > 0$: régularisation parcimonieuse
 - iii) Reformulation d'un problème d'optimisation avec contraintes

$$\begin{aligned} \min_{x \in \mathcal{C}} f(x) \text{ avec } \mathcal{C} \text{ convexe } \neq \emptyset \text{ de } \mathbb{R}^n \\ \Rightarrow \text{"pénalisation"} \quad g(x) = \begin{cases} 0 & \text{si } x \in \mathcal{C} \\ +\infty & \text{sinon} \end{cases} \end{aligned}$$

$$\min_{x \in \mathbb{R}^n} h(x) = f(x) + g(x)$$

2) Exemples d'applications

exemple 1: Moindres carrés régularisés.

On dispose d'un modèle linéaire :

$$\forall x \in \mathbb{R}^n \quad f(x, \beta) = x^T \beta \text{ avec } \beta \in \mathbb{R}^n \text{ paramètres inconnus}$$

On dispose d'observations $(x_i, y_i) \in (\mathbb{R}^n \times \mathbb{R}^P)$ permettant d'estimer β . D'où le problème d'optimisation :

$$\min_{\beta \in \mathbb{R}^n} \frac{1}{2} \sum_{i=1}^P (f(x_i, \beta) - y_i)^2 \Leftrightarrow \min_{\beta \in \mathbb{R}^n} \frac{1}{2} \|X\beta - y\|_2^2$$

$$\text{avec } X = \begin{bmatrix} x_1^T \\ \vdots \\ x_P^T \end{bmatrix} \in \mathbb{M}_{P, n}(\mathbb{R}) \quad y = (y_i) \in \mathbb{R}^P$$

\Rightarrow terme de régularisation : $\min_{\beta \in \mathbb{R}^n} \frac{1}{2} \|X\beta - y\|_2^2 + g(\beta)$

i) $g(\beta) = \frac{\lambda}{2} \|\beta\|_2^2$ régularisation de Tikhonov

ii) $g(\beta) = \lambda \|\beta\|_1$ régularisation parcimonieuse (LASSO)

iii) $g(\beta) = \frac{\lambda}{2} \|\beta\|_B^2$ avec $\|\beta\|_B^2 = \beta^T B \beta$ et $B \in S_n(\mathbb{R})$ définie positive

régularisation de Tikhonov généralisée

iv) $g(\beta) = \frac{\lambda}{p} \|\beta\|_p^p$ avec $p > 1$ et $\|\beta\|_p = \left[\sum_{i=1}^m |\beta_i|^p \right]^{1/p}$

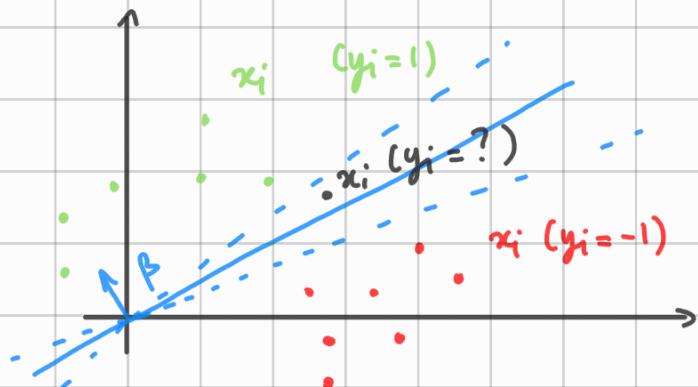
Rem: $S_m(\mathbb{R})$: matrice symétrique

exemple 2: SVM séparateur à vaste marge

On dispose de données $(x_i) \in (\mathbb{R}^n)^P$ labellisées $(y_i)_{i \in [1, P]} \in [-1, 1]^P$

On cherche à construire un hyperplan séparant les données (x_i) selon leurs labels (y_i)

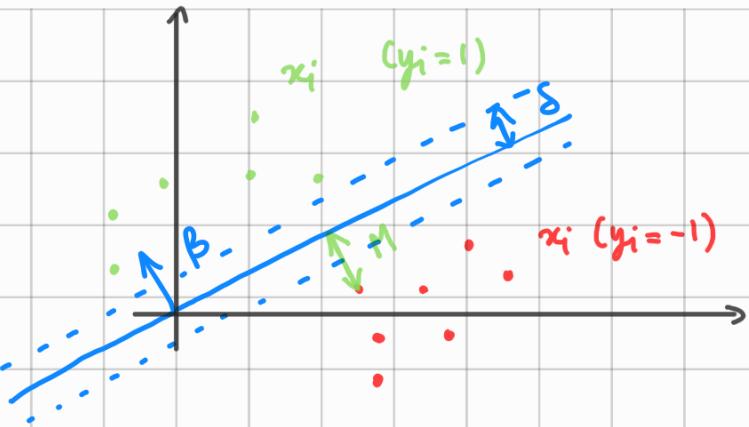
. Dans un premier temps on suppose qu'il existe un tel hyperplan de vecteur normal $\beta \in \mathbb{R}^n$ passant par l'origine.



la classe du nouvel x_i
dépend de l'hyperplan choisi
Q? quel hyperplan
choisir?

\Rightarrow incertitude : nombre de données, répartition dans \mathbb{R}^n , etc...

\Rightarrow maximiser la distance minimale entre les données et l'hyperplan.



Condition de séparabilité : $\forall i \in [1, p] \quad y_i x_i^\top \beta \geq 0$
 d'où le problème d'optimisation :

$$\begin{aligned} & \max M \\ & (\beta, M) \in \mathbb{R}^n \times \mathbb{R}^+ \\ & \text{s.c. } \forall i \in [1, p] \quad \frac{y_i x_i^\top \beta}{\|\beta\|_2} \geq M \end{aligned}$$

Rem: $d(z, \{\beta^\top z = 0\}) = \frac{\|\beta\|_2}{\|\beta\|_2}$

- En pratique, la condition de séparabilité n'est pas vérifiée pour tout $i \in [1, p]$
 ⇒ pénalisation des contraintes non satisfaites

On pose $\forall t \in \mathbb{R} \quad t^+ = \max(t, 0)$

Ceci conduit à formuler un autre problème d'optimisation :

$$\max_{(\beta, M) \in \mathbb{R}^n \times \mathbb{R}^+} M - \lambda \sum_{i=1}^p \left(1 - \frac{y_i x_i^\top \beta}{\|\beta\|_2 M} \right)_+ \quad \text{avec } \lambda > 0$$

Avec $\|\beta\|_2 = \frac{1}{M}$ et en reformulant pour obtenir un problème de minimisation :

$$\min_{\beta \in \mathbb{R}^n} \|\beta\|_2^2 + \lambda \sum_{i=1}^p (1 - y_i x_i^\top \beta)_+$$

non lisse

3) Rappels de convexité

def: Soit $E \subset \mathbb{R}^n$ E est une partie convexe de \mathbb{R}^n si

$$\forall (x, y) \in \mathcal{C}^2 \quad \forall \lambda \in [0, 1] \quad \lambda x + (1-\lambda)y \in \mathcal{C}$$

ex i) partie affine $x_0 + S$ avec S sous espace de \mathbb{R}^n et $x_0 \in \mathbb{R}^n$
 $:= \{x_0 + s, \text{ avec } s \in S\}$

ii) hyperplan $\{x \in \mathbb{R}^n \mid q^T x = b\}$

iii) Demi-espace $\{x \in \mathbb{R}^n \mid q^T x \leq b\}$

iv) polyèdre : $\{Ax \leq b\}$ avec A matrice

v) ellipsoïde : $\{x \in \mathbb{R}^n \mid q^T \mathcal{C} x \leq 1\}$ avec $\mathcal{C} \in \mathbb{S}_m(\mathbb{R})$ semi définie positive

propriété: opérations préservant la convexité

i) intersection

ii) somme

iii) multiplication par un scalaire.

iv) produit cartésien

v) image réciproque d'une application linéaire $U^{-1}(\mathcal{C})$
 \mathcal{C} convexe

vi) Image directe par une application linéaire

vii) projection : $\{x_i \mid q(x_1/x_2) \in \mathcal{C}\}$ avec \mathcal{C} convexe

def: fonction convexe sur \mathcal{C} convexe

$f: \mathcal{C} \rightarrow \mathbb{R}$ avec \mathcal{C} convexe de \mathbb{R}^n

f est convexe sur \mathcal{C} (convexe) si $\forall (x, y) \in \mathcal{C}^2 \quad \forall \lambda \in [0, 1]$

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$$

f est strictement convexe sur \mathcal{C} (convexe) si $\forall (x, y) \in \mathcal{C}^2 \quad \forall \lambda \in]0, 1[$

$$x \neq y \quad f(\lambda x + (1-\lambda)y) < \lambda f(x) + (1-\lambda)f(y)$$

propriété: CNS convexité dans le cas dérivable

Soit $f: \Omega \rightarrow \mathbb{R}$ avec Ω ouvert et $\mathcal{C} \subset \Omega$ convexe

1) Si f est dérivable sur Ω , alors

$$f \text{ convexe sur } \mathcal{C} \text{ convexe} \Leftrightarrow \forall (x, y) \in \mathcal{C}^2 \quad f(y) \geq f'(x)(y-x) + f(x)$$

$$\Leftrightarrow \forall (x, y) \in \mathcal{C}^2 \quad f(y) \geq \nabla f(x)^T (y-x) + f(x)$$

2) Si f est deux fois dérivable sur Ω , f convexe sur \mathcal{C} convexe

$$\Leftrightarrow \forall (x, y) \in \mathcal{C}^2 \quad f''(x)(y-x, y-x) \geq 0$$

$$\Leftrightarrow \forall (x, y) \in \mathcal{C}^2 \quad (y-x)^T \nabla^2 f(x)(y-x) \geq 0$$

propriété Soit \mathcal{C} convexe de \mathbb{R}^n Soit $f: \mathcal{C} \rightarrow \mathbb{R}$

f est convexe sur \mathcal{C} convexe $\Leftrightarrow \forall x \in \mathcal{C} \quad \forall r \in \mathbb{R}^n$

$t \mapsto f(x+tr)$ est convexe sur
 $\{t \in \mathbb{R} \mid t \geq 0, x+tr \in \mathcal{C}\}$ convexe

propriété

i) f convexe sur \mathcal{C} convexe $\Rightarrow \alpha f$ convexe sur \mathcal{C} convexe avec $\alpha > 0$

ii) combinaisons linéaires à coefficients positifs de fonctions convexes sont convexes.

iii) f convexe sur \mathcal{C} convexe

Soyons $A \in M_{m,n}(\mathbb{R})$ et $b \in \mathbb{R}^m$ alors $\mathcal{C}' = \{x \in \mathbb{R}^n \mid \forall A x + b \in \mathcal{C}\}$ est convexe et $x \mapsto f(Ax + b)$ convexe sur \mathcal{C}'

iv) $(f_i)_{i \in [1, m]}$ convexes sur $(\mathcal{C}_i)_{i \in [1, m]}$ alors

$\max_{i \in [1, m]} f_i$ est convexe sur $\bigcap_{i=1}^m \mathcal{C}_i$

v) $g: \mathbb{R}^n \rightarrow \mathbb{R}$ convexe sur $\mathcal{C} \subset \mathbb{R}^n$

$h: \mathbb{R}^n \rightarrow \mathbb{R}$ convexe sur \mathcal{C}' tq $g(\mathcal{C}) \subset \mathcal{C}'$ et croissante alors $h \circ g$ est convexe sur \mathcal{C}

vi) $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$ avec $\forall i \in [1, p] \quad g_i$ convexe sur \mathbb{R}^n

$h: \mathbb{R}^p \rightarrow \mathbb{R}$ convexe et croissante vis-à-vis de chacun de ses arguments alors $f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$x \mapsto h(g(x)) = h(g_1(x), \dots, g_p(x))$$

est convexe sur \mathbb{R}^n

4) Régularité des fonctions convexes

def : épigraphe de f

Soit $f: \mathcal{C} \rightarrow \mathbb{R}$ on appelle épigraphe de f noté $\mathcal{E}(f)$,

$$\mathcal{E}(f) = \{(x, w) \in \mathcal{C} \times \mathbb{R} \text{ tq } f(x) \leq w\}$$

propriété:

$f: \mathcal{C} \rightarrow \mathbb{R}$ avec \mathcal{C} convexe de \mathbb{R}^n

f convexe sur \mathcal{C} convexe $\Rightarrow \mathcal{E}(f)$ convexe

preuve \Rightarrow Supposons f convexe sur \mathcal{C} convexe

$$\forall (x, y) \in \mathcal{C}^2 \quad \forall \lambda \in [0, 1] \quad f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$$

Soient $(x_1, w_1) \in \mathcal{E}(f)$, $(x_2, w_2) \in \mathcal{E}(f)$ et $\lambda \in [0, 1]$

$(\lambda x_1 + (1-\lambda)x_2, \lambda w_1 + (1-\lambda)w_2) \in \mathcal{E}(f)$?

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \underbrace{\lambda f(x_1)}_{\leq w_1} + \underbrace{(1-\lambda)f(x_2)}_{\leq w_2} \quad \begin{array}{l} \text{par convexité de } f \text{ sur } \mathcal{C} \\ \text{par définition de } \mathcal{E}(f) \end{array}$$
$$\leq \lambda w_1 + (1-\lambda)w_2$$

$$\Rightarrow (\lambda x_1 + (1-\lambda)x_2, \lambda w_1 + (1-\lambda)w_2) \in \mathcal{E}(f)$$

$$\Rightarrow \lambda(x_1, w_1) + (1-\lambda)(x_2, w_2) \in \mathcal{E}(f) \quad \Rightarrow \mathcal{E}(f) \text{ convexe}$$

\Leftarrow Supposons $\mathcal{E}(f)$ convexe

Soient $(x, y) \in \mathcal{C}^2$, $\lambda \in [0, 1]$

on $(x, f(x)) \in \mathcal{E}(f)$ et $(y, f(y)) \in \mathcal{E}(f)$

d'où par convexité de $\mathcal{E}(f)$

$$\lambda(x, f(x)) + (1-\lambda)(y, f(y)) \in \mathcal{E}(f)$$

$$\Rightarrow f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$$

par déf de $\mathcal{E}(f)$

propriété : Inégalité de Jensen

Soit $f: \mathcal{C} \rightarrow \mathbb{R}$ avec \mathcal{C} convexe de \mathbb{R}^n

$\forall (x_i)_{i \in [1, p]} \in \mathbb{C}^p \quad \forall (\lambda_i)_{i \in [1, p]} \in \mathbb{R}^p$ tq $\forall i \in [1, p] \quad \lambda_i \geq 0$

et $\sum_{i=1}^p \lambda_i = 1$

alors $f\left(\sum_{i=1}^p \lambda_i x_i\right) \leq \sum_{i=1}^p \lambda_i f(x_i)$

propriété: Soit $f: \mathbb{C} \rightarrow \mathbb{R}$ avec \mathbb{C} convexe de \mathbb{R}^n

Soit $x_0 \in \mathbb{C}$ alors f est continue en x_0 .

preuve: Soit $x_0 \in \mathbb{C}$

Soit Δ un simplexe inclus dans \mathbb{C} et contenant x_0 :

Notons $(\Delta_i)_{i \in [1, n+1]}$ les sommets de Δ

$\forall x \in \Delta, \exists! (\lambda_i)_{i \in [1, n+1]} \in \mathbb{R}^{n+1}$ tq $\lambda_i \geq 0 \quad \forall i \in [1, n+1]$,

$$\sum_{i=1}^{n+1} \lambda_i = 1 \quad \text{et} \quad x = \sum_{i=1}^{n+1} \lambda_i \Delta_i$$

(coordonnées barycentriques de x mis-à-mis de Δ)

d'où $f(x) \leq \sum_{i=1}^{n+1} \lambda_i f(\Delta_i)$ par convexité de f et inégalité de

Jensen

$$\leq \max_{j \in [1, n+1]} f(\Delta_j) \underbrace{\sum_{i=1}^{n+1} \lambda_i}_{=1 \text{ par def de } (\lambda_i)_{i \in [1, n+1]}}$$

$$\leq \max_{j \in [1, n+1]} f(\Delta_j)$$

$\Rightarrow f$ est majorée sur Δ

En particulier $\forall \delta > 0$ tq $B(x_0, \delta) \subset \Delta$,

f majorée sur $B(x_0, \delta)$

Fixons un tel δ et notons M un majorant de f sur $B(x_0, \delta)$

Soit $z \in B(x_0, \delta)$, on pose $z' = 2x_0 - z$

$$\text{alors } z' \in B(x_0, \delta) : \|z' - x_0\| = \|x_0 - z\| < \delta$$

Alors $x_0 \in [z, z']$

Pour convexité de f sur \mathcal{C} : $f(x_0) \leq \frac{1}{2} f(z) + \frac{1}{2} \underbrace{f(z')}_{\leq M \text{ car } z' \in \mathcal{B}(x_0, \delta)}$

$$\Rightarrow f(z) \geq 2f(x_0) - M$$

Bilan : $2f(x_0) - M \leq f(z) \leq M \quad \forall z \in \mathcal{B}(x_0, \delta)$

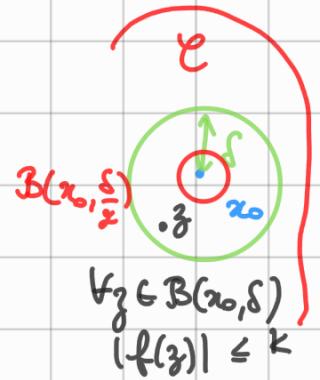
$\Rightarrow f$ bornée sur $\mathcal{B}(x_0, \delta)$

Soit $K > 0$ tq $\forall z \in \mathcal{B}(x_0, \delta) \quad |f(z)| \leq K$

Mq f est lipschitzienne sur $\mathcal{B}(x_0, \frac{\delta}{2})$

Soient $(x, y) \in \mathcal{B}(x_0, \frac{\delta}{2})^2$

On pose $\begin{cases} x' = x - \frac{\delta}{2} \frac{y-x}{\|y-x\|} \\ y' = y + \frac{\delta}{2} \frac{y-x}{\|y-x\|} \end{cases}$



$$\text{alors } x' \in \mathcal{B}(x_0, \delta) : \|x' - x_0\| = \|x - x_0 - \frac{\delta}{2} \frac{y-x}{\|y-x\|}\|$$

$$\leq \underbrace{\|x - x_0\|}_{\leq \frac{\delta}{2}} + \frac{\delta}{2} \\ < \frac{\delta}{2} \text{ car } x \in \mathcal{B}(x_0, \frac{\delta}{2})$$

$$< \frac{\delta}{2}$$

Idem pour $y' \in \mathcal{B}(x_0, \delta)$

d'où $|f(x')| \leq K$ et $|f(y')| \leq K$

$$\text{De plus, } x = \underbrace{\frac{2\|y-x\|}{2\|y-x\|+\delta} x'}_{i=\lambda \in [0,1]} + \underbrace{\frac{\delta}{2\|y-x\|+\delta}}_{=1-\lambda} y \quad y = \lambda x' + (1-\lambda)y$$

Par convexité de f sur \mathcal{C} : $f(x) \leq \lambda f(x') + (1-\lambda) f(y)$

$$\Rightarrow f(x) - f(y) \leq \lambda (f(x') - f(y)) \\ \leq 2K\lambda$$

$$\leq \frac{4K}{\delta \|y-x\| + \delta} \|y-x\|$$

$$\Rightarrow f(x) - f(y) \leq \frac{4K}{\delta} \|y-x\|$$

De même $y = \lambda y' + (1-\lambda)x$ et de la même manière

$$f(y) - f(x) \leq \frac{4K}{\delta} \|y-x\|$$

$$\Rightarrow |f(y) - f(x)| \leq \frac{4K}{\delta} \|y-x\| \quad \forall (x,y) \in B(x_0, \frac{\delta}{2})$$

Bilan: f $\frac{4K}{\delta}$ -lipschitzienne sur $B(x_0, \frac{\delta}{2})$

En particulier f continue en x_0 .

II. Sous différentiel d'une fonction

1) Sous-gradient, sous-différentiel

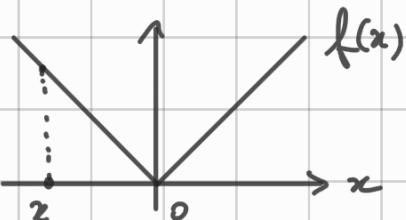
def: $f: \mathcal{C} \rightarrow \mathbb{R}$ avec $\mathcal{C} \subset \mathbb{R}^n$ Soient $x \in \mathcal{C}$ et $g \in \mathbb{R}^n$

g est appelé sous-gradient de f en x si

$$\forall y \in \mathcal{C} \quad f(y) \geq g^T(y-x) + f(x)$$

On appelle sous différentiel de f en x noté $\partial f(x)$, l'ensemble des sous gradients de f en x

ex: $f: \mathbb{R} \rightarrow \mathbb{R}$
 $x \mapsto |x|$



Soit $x \in \mathbb{R}$ Q? $\partial f(x)$?

1^{er} cas $x < 0$

alors $f(x) = -x$

Soit $g \in \mathbb{R}$ tq $\forall y \in \mathbb{R} \quad f(y) \geq g(y-x) + f(x)$

Soit $y \geq 0$ $f(y) = -y = -y + x - x = -(y-x) + f(x)$

$$\Leftrightarrow -(y-x) + f(x) \geq g(y-x) + f(x)$$

$$\Leftrightarrow -(1+g)(y-x) \geq 0 \quad \forall y \geq 0$$

$$\Leftrightarrow g = -1$$

Soit $y > 0$ $f(y) = y \geq -y \geq -(y-x) + f(x) \geq g(y-x) + f(x)$

OK avec $g = -1$

$$\text{d'où } \partial f(x) = \{-1\}$$

2^e cas $\partial f(x) = \{1\}$

3^e cas $x=0$ $f(x=0)$

Soit $g \in \mathbb{R}$ tq $\forall y \in \mathbb{R}$ $f(y) \geq g(y-x) + f(x) \geq gy$

Soit $y > 0$ $f(y) = y$

$$f(y) \geq gy \Leftrightarrow (1-g)y \geq 0$$

$$\Leftrightarrow g \leq 1$$

• Soit $y \leq 0$ $f(y) = -y$ $f(y) \geq gy \Leftrightarrow -(1+g)y \geq 0$
 $\Leftrightarrow g \geq -1$

$$\rightarrow g \in [-1, 1]$$

On vérifie $\partial f(0) = [-1, 1] \setminus 0$

propriété: Soit $f: \mathcal{C} \rightarrow \mathbb{R}$ avec $\mathcal{C} \subset \mathbb{R}^n$

Soit $x \in \mathcal{C}$ Alors $\partial f(x) = \emptyset$ ou $\partial f(x)$ est une partie convexe fermée de \mathbb{R}^n

preuve: Supposons $\partial f(x) \neq \emptyset$ alors $\partial f(x) = \bigcap_{y \in \mathcal{C}} \{g \in \mathbb{R}^n \mid q f(y) \geq g^T(y-x) + f(x)\}$

or $\forall y \in \mathcal{C} \quad \{g \in \mathbb{R}^n \mid q f(y) \geq g^T(y-x) + f(x)\}$

est convexe (demi-espace) et fermée comme image

réciproque d'un fermé par une application continue avec $\Psi: \mathbb{R}^n \rightarrow \mathbb{R}$

$$g \mapsto f(y) - f(x)$$

$$-g^T(y-x)$$

$\Rightarrow \delta f(x)$ convexe fermé comme intersection de parties convexes et fermées

propriété: Soit $f: E \rightarrow \mathbb{R}$ avec $E \subset \mathbb{R}^n$

Soit $x \in E$ tq f continue en x alors $\delta f(x)$ est borné

preuve: Soit $x \in E$ tq f continue en x

$x \in E : \exists y_1 > 0$ tq $B(x, y_1) \subset E$ f continue en x

$\forall \varepsilon > 0 \quad \exists y_2 > 0$ tq $\forall y \in B(x, y_2) \quad |f(y) - f(x)| < \varepsilon$

Posons $y = \min(y_1, y_2)$

Mq $\delta f(x)$ borné

Supposons le contraire

$\forall M > 0 \quad \exists g \in \delta f(x)$ tq $\|g\| > M$

Soit $M > 0$ Fixons un tel $g \in \delta f(x) \Rightarrow g \neq 0$

Soit $y = x + \frac{\eta}{2} \frac{g}{\|g\|}$

D'où $\|y - x\| = \frac{\eta}{2} \Rightarrow y \in B(x, y) \subset E$

Par définition de $g \in \delta f(x)$

$$f(y) \geq g^T(y-x) + f(x)$$

$$f(y) - f(x) \geq \frac{\eta}{2} \|g\| > \frac{\eta}{2} M \text{ par hypothèse.}$$

$$\text{Avec } M = \frac{2}{\eta} \varepsilon \quad f(y) - f(x) > \varepsilon$$

Or $y \in B(x, y) \Rightarrow y \in B(x, y_2) \Rightarrow |f(y) - f(x)| < \varepsilon$

d'où $\varepsilon < f(y) - f(x) < \varepsilon$ contradiction

d'où $\partial f(x)$ borné

propriété : $f: \mathcal{C} \rightarrow \mathbb{R}$ convexe sur \mathcal{C} convexe de \mathbb{R}^n

i) $\forall x \in \mathcal{C} \quad \partial f(x) \neq \emptyset$

Et $\partial f(x)$ compact convexe $\neq \emptyset$ de \mathbb{R}^n

ii) Si f dérivable en $x \in \mathcal{C}$ alors $\partial f(x) = \{\nabla f(x)\}$

preuve :

i) lemme : Soit \mathcal{C} convexe $\neq \emptyset$ de \mathbb{R}^n

Soit $x_0 \in C_p \cup (\bar{\mathcal{C}} \setminus \mathcal{C})$

alors $\exists a \in \mathbb{R}^n \setminus \{0\}$ tq $\sup_{z \in \mathcal{C}} a^T z \leq a^T x_0$

C_p complémentaire
de \mathcal{C} dans
 \mathbb{R}^n

$\bar{\mathcal{C}} \setminus \mathcal{C}$ frontière
de \mathcal{C} .

Soit $x \in \mathcal{C}$ En particulier $(x, f(x)) \in \bar{\mathcal{E}}(f) \setminus \mathcal{E}(f)$

De plus f convexe $\Rightarrow \mathcal{E}(f)$ convexe

d'où par lemme

$$\exists (a, \alpha) \in (\mathbb{R}^n \times \mathbb{R}) \setminus \{0\} \text{ tq } \forall (y, \omega) \in \mathcal{C} \times \mathbb{R}$$

$$[a^T \alpha] \begin{bmatrix} y \\ \omega \end{bmatrix} \leq [a^T \alpha] \begin{bmatrix} x \\ f(x) \end{bmatrix}$$

$$\Leftrightarrow a^T(y-x) + \alpha(\omega - f(x)) \leq 0$$

Si $\alpha > 0$ alors $a^T(y-x) \leq \alpha(f(x)-\omega)$

impossible

$$\rightarrow -\infty$$

$$\omega \rightarrow +\infty$$

Si $\alpha = 0$ alors $a^T(y-x) \leq 0$

or $x \in \mathcal{C}^\circ$: $\exists N \in \mathbb{N}$ tq $\forall n \geq N \quad y_n = x + \frac{a}{n} \in \mathcal{C}$

d'où $\forall n \geq N \quad \frac{\|a\|^2}{n} \leq 0 \Rightarrow a=0$ impossible car $\begin{bmatrix} a \\ \alpha \end{bmatrix} \neq 0$

d'où $\alpha < 0$

Il vient $a^T(y-x) \leq \alpha(f(x)-\omega) \Rightarrow f(x)-\omega \leq \left[\frac{a}{\alpha}\right]^T(y-x)$

$$\Rightarrow w \geq f(x) + \left[-\frac{a}{\alpha} \right]^T (y-x)$$

En particulier avec $w = f(y)$

$$\Rightarrow f(y) \geq f(x) + \left[-\frac{a}{\alpha} \right]^T (y-x) \quad \forall y \in \mathcal{C} \Rightarrow -\frac{a}{\alpha} \in \partial f(x)$$

$$\Rightarrow \partial f(x) \neq \emptyset$$

ii) On suppose de plus f dérivable en $x \in \mathring{\mathcal{C}}$

+ f convexe sur \mathcal{C} convexe et dérivable en $x \in \mathring{\mathcal{C}}$

$$\Rightarrow \forall y \in \mathcal{C} \quad f(y) \geq \nabla f(x)^T (y-x) + f(x)$$

$$\Rightarrow \nabla f(x) \in \partial f(x)$$

$$\Rightarrow \{\nabla f(x)\} \subset \partial f(x)$$

Soit $g \in \partial f(x)$

$$\forall y \in \mathcal{C} \quad f(y) \geq g^T (y-x) + f(x)$$

Or $x \in \mathring{\mathcal{C}}$ $\exists N \in \mathbb{N}$ tq $\forall m \in \mathbb{N}$ $y_m = x + \frac{u}{m} \in \mathcal{C}$ avec $u \in \mathbb{R}^n$

Fixons un tel N

$$\forall m \in \mathbb{N} \quad f(y_m) \geq \frac{1}{m} g^T u + f(x)$$

Or f dérivable en x :

$$f(y_m) = f(x) + \frac{1}{m} \nabla f(x)^T u + \frac{1}{m} \|u\| \varepsilon \left(\frac{1}{m} u \right) \text{ avec } \varepsilon(h) \xrightarrow[h \rightarrow 0]{} 0$$

$$\Leftrightarrow f(x) + \frac{1}{m} \nabla f(x)^T u + \frac{1}{m} \|u\| \varepsilon \left(\frac{u}{m} \right) \geq \frac{1}{m} g^T u + f(x)$$

$$\Leftrightarrow (\nabla f(x) - g)^T u + \underbrace{\|u\| \varepsilon \left(\frac{u}{m} \right)}_{\xrightarrow[m \rightarrow +\infty]{} 0} \geq 0$$

À la limite $(\nabla f(x) - g)^T u \geq 0 \quad \forall u \in \mathbb{R}^n$

$$\Rightarrow g = \nabla f(x) \text{ et } \partial f(x) \subset \{\nabla f(x)\}$$

Bilan: $\partial f(x) = \{\nabla f(x)\}$

propriété $f: \mathcal{C} \rightarrow \mathbb{R}$ convexe sur \mathcal{C} convexe

Soit $x^* \in \mathcal{C}$

x^* minimum global de f sur $\mathcal{C} \Leftrightarrow 0 \in \partial f(x^*)$

preuve: $0 \in \partial f(x^*) \Leftrightarrow \forall y \in \mathcal{C} \quad f(y) \geq 0^T(y - x^*) + f(x^*)$
 $\Leftrightarrow \forall y \in \mathcal{C} \quad f(y) \geq f(x^*)$
 $\Leftrightarrow x^*$ minimum global de f sur \mathcal{C}

2) Calculs de sous-gradiants

Pour simplifier, on suppose avoir (f_i) convexes sur \mathbb{R}^n

propriété

i) Soit $(\alpha_1, \alpha_2) \in \mathbb{R}_+^{2 \times 2}$

On pose $f = \alpha_1 f_1 + \alpha_2 f_2$

alors $\partial f(x) = \alpha_1 \partial f_1(x) + \alpha_2 \partial f_2(x)$

ii) $h: \mathbb{R}^n \rightarrow \mathbb{R}$

$x \mapsto f(Ax+b)$ avec $A \in M_{p,n}(\mathbb{R}) \quad b \in \mathbb{R}^p$

f convexe sur \mathbb{R}^p

$$\partial h(x) = A^T \partial f(Ax+b)$$

iii) $f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$x \mapsto \max_{i \in [1,p]} f_i(x)$$

Soit $I_0 = \{i \in [1,p] \mid f_i(x) = \max_{j \in [1,p]} f_j(x)\}$

Hg $\partial f_{i_0}(x)$ avec $i_0 \in I_0, g \in \partial f(x)$

$$\text{iv) } f: \mathbb{R}^n \rightarrow \mathbb{R}$$

$$x \mapsto \sup_{\alpha \in A} f_\alpha(x)$$

Où note $I_0 = \{\alpha \in A \text{ tq } f_\alpha(x) = \sup_{\beta \in A} f_\beta(x)\}$

$\forall g \in \partial f_\alpha(x) \text{ avec } \alpha \in I_0 \quad g \in \partial f(x)$

III. Algorithmes de sous-gradient

1) algorithme du sous-gradient

$$(P) \min_{x \in \mathbb{R}^n} f(x) \text{ avec } f \text{ convexe sur } \mathbb{R}^n \text{ (convexe)}$$

On suppose que f admet au moins un minimum $x^* \in \mathbb{R}^n$

Algo: $x_0 \in \mathbb{R}^n$

Tant que

calculer $g_k \in \partial f(x_k)$

$$x_{k+1} = x_k - \alpha_k g_k \text{ avec } \alpha_k > 0$$

Fin Tant que

Rem: f convexe sur $\mathbb{R}^n \Rightarrow \forall x \in \mathbb{R}^n \partial f(x) \neq \emptyset$ et
 $\partial f(x)$ est un compact convexe de \mathbb{R}^n

Soit $k \in \mathbb{N}$

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &= \|x_k - \alpha_k g_k - x^*\|^2 \\ &= \|x_k - x^*\|^2 - 2x_k^T g_k + \alpha_k^2 \|g_k\|^2 \end{aligned}$$

or $g_k \in \partial f(x_k)$

d'où $\forall y \in \mathbb{R}^n \quad f(y) \geq g_k^T (y - x_k) + f(x_k)$

En particulier $f(x^*) \geq g_k^T (x^* - x_k) + f(x_k)$

$$\Rightarrow -g_k^T (x_k - x^*) \leq f(x^*) - f(x_k)$$

$$\text{d'où } \|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2 - 2\alpha_k (f(x_k) - f(x^*)) \\ + \alpha_k^2 \|g_k\|^2$$

Par récurrence

$$\|x_{k+1} - x^*\|^2 \leq \|x_1 - x^*\|^2 - 2 \sum_{l=1}^k \alpha_l (f(x_l) - f(x^*)) \\ + \sum_{l=1}^k \alpha_l^2 \|g_l\|^2$$

On pose $f_{best}^k = \min_{j \in [1, k]} f(x_j)$

$$\text{On a } 2 \sum_{l=1}^k \alpha_l (\underbrace{f(x_l) - f(x^*)}_{\geq f_{best}^k - f(x^*)}) \leq \|x_1 - x^*\|^2 + \sum_{l=1}^k \alpha_l^2 \|g_l\|^2$$

$$\Rightarrow 0 \leq f_{best}^k - f(x^*) \leq \frac{\|x_1 - x^*\|^2 + \sum_{l=1}^k \alpha_l^2 \|g_l\|^2}{2 \sum_{l=1}^k \alpha_l}$$

Soit $R > 0$ tq $\|x_1 - x^*\| \leq R$

$$0 \leq f_{best}^k - f(x^*) \leq \frac{R^2 + \sum_{l=1}^k \alpha_l^2 \|g_l\|^2}{2 \sum_{l=1}^k \alpha_l}$$

On suppose de plus $\exists a > 0$ tq $\forall l \in \mathbb{N} \quad \|g_l\| \leq a$

$$\Rightarrow 0 \leq f_{\text{best}}^k - f(x^*) \leq \frac{R^2 + \alpha^2 \sum_{l=1}^k \alpha_l^2}{2 \sum_{l=1}^k \alpha_l}$$

Q? Quelle est la stratégie de pas α_l ?

① Pas constant : $\forall l \in [1, k] \quad \alpha_l = \alpha > 0$

$$0 \leq f_{\text{best}}^k - f(x^*) \leq \frac{R^2 - \alpha^2 \alpha^2 k}{2 \alpha k} \xrightarrow[k \rightarrow +\infty]{} \frac{\alpha^2 \alpha}{2}$$

$$\Rightarrow f_{\text{best}}^k \in \mathcal{B}(f(x^*), \frac{\alpha^2 \alpha}{2})$$

$$\begin{cases} \forall l \in \mathbb{N} \quad \alpha_l > 0 \\ \sum_{l=1}^k \alpha_l \xrightarrow[m \rightarrow +\infty]{} +\infty \\ \sum_{l=1}^k \alpha_l^2 < +\infty \end{cases} \quad \text{Alors} \quad 0 \leq f_{\text{best}}^k - f(x^*) \leq \frac{R^2 + \alpha^2 \sum_{l=1}^k \alpha_l^2}{\sum_{l=1}^k \alpha_l} \xrightarrow[k \rightarrow +\infty]{} 0$$

$$\text{donc } f_{\text{best}}^k \xrightarrow[k \rightarrow +\infty]{} f(x^*)$$

$$\text{③ } \forall l \in \mathbb{N} \quad \alpha_l = \frac{\gamma_l}{\|g_l\|} \quad \text{avec}$$

$$\begin{cases} \gamma_l > 0 \\ \gamma_l \xrightarrow[l \rightarrow +\infty]{} 0 \\ \sum_{l=1}^k \gamma_l \xrightarrow[k \rightarrow +\infty]{} +\infty \end{cases}$$

Et plus généralement :

$$\begin{cases} \alpha_l > 0 \quad \forall l \in \mathbb{N} \\ \alpha_l \xrightarrow[l \rightarrow +\infty]{} 0 \\ \sum_{l=1}^k \alpha_l \xrightarrow[k \rightarrow +\infty]{} +\infty \end{cases}$$

$$\alpha_l \xrightarrow[l \rightarrow +\infty]{} 0$$

$$\forall \varepsilon > 0 \quad \exists N_1 \in \mathbb{N} \quad \forall l \in N_1 \quad |\alpha_l| < \frac{\varepsilon}{\alpha^2} = \frac{\varepsilon}{\alpha^2} \quad \text{car } \alpha_l > 0$$

$$\text{En particulier} \quad \alpha_l^2 \leq \alpha_l \frac{\varepsilon}{\alpha^2}$$

$$\forall k \geq N_1 + 1$$

$$0 \leq f_{\text{best}}^k - f(x^*) \leq \frac{R^2 + a^2 \sum_{l=1}^{N_1} \alpha_l^2}{2 \sum_{l=1}^k \alpha_l} + \frac{a^2 \sum_{l=N+1}^k \alpha_l^2}{2 \sum_{l=1}^k \alpha_l} \sim \alpha_l \frac{\varepsilon}{a^2}$$

$$< \frac{R^2 + a^2 \sum_{l=1}^{N_1} \alpha_l^2}{2 \sum_{l=1}^k \alpha_l} + \underbrace{\frac{\varepsilon}{2} \frac{\sum_{l=N+1}^k \alpha_l}{\sum_{l=1}^k \alpha_l}}_{\leq 1 \text{ car } \alpha_l > 0}$$

D'après plus $\sum_{l=1}^k \alpha_l \rightarrow +\infty$

$$\exists N_2 \in \mathbb{N} \text{ tq } \forall k \geq N_2 \quad \sum_{l=1}^k \alpha_l \geq \frac{R^2 + a^2 \sum_{l=1}^{N_1} \alpha_l}{\varepsilon}$$

d'où $\forall k \geq \max(N_1, N_2)$

$$0 \leq f_{\text{best}}^k - f(x^*) < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon \text{ et ce que } \varepsilon > 0$$

$$\Rightarrow f_{\text{best}}^k \xrightarrow{k \rightarrow +\infty} f(x^*)$$

Rem:

On s'intéresse à la stratégie de pas qui minimise

$$\Psi(\alpha) = \frac{R^2 + a^2 \|\alpha\|_2^2}{2 \|\alpha\|_1} \text{ avec } \alpha \in (R_+^*)^{L+1}$$

Avec une telle stratégie de pas, il pourra être nécessaire de faire $O\left(\frac{1}{\varepsilon^2}\right)$ itérations pour atteindre $|f_{\text{best}}^k - f(x^*)| < \varepsilon$ (cf TD1)

$$\varepsilon = 10^{-3} \Rightarrow 10^6 \text{ itérations}$$

→ l'algorithme est très lent dans le pire cas

2) algorithme du sous-gradient projeté

$\min_{x \in \mathcal{C}} f(x)$ avec \mathcal{C} convexe fermé non vide de \mathbb{R}^n

(P) $\min_{x \in \mathcal{C}} f(x)$ avec \mathcal{C} partie convexe, fermée, non vide de \mathbb{R}^n

On suppose que (P) admette au moins une solution $x^* \in \mathcal{C}$

Rem: \mathcal{C} partie convexe fermée $\neq \emptyset$ de \mathbb{R}^n :

la projection orthogonale sur \mathcal{C} , notée $\Pi_{\mathcal{C}}$, est 1-lipschitzienne
(cf cours analyse hilberienne)

$$\forall (x, y) \in (\mathbb{R}^n)^2 \quad \|\Pi_{\mathcal{C}}(x) - \Pi_{\mathcal{C}}(y)\| \leq \|x - y\|$$

Soit $x \in \mathbb{R}^n \quad \|x - \Pi_{\mathcal{C}}(x)\| = \min_{y \in \mathcal{C}} \|x - y\|$

Idee: projeté orthogonale sur \mathcal{C} des itérations de l'algorithme de sous gradient

Algo: $x_0 \in \mathbb{R}^n$

Tant que

Calculer $g_k \in \partial f(x_k)$

$$x_{k+1} = \Pi_{\mathcal{C}}(x_k - \alpha_k g_k)$$

Fin Tant que

Q? Convergence?

Soit $z_{k+1} = x_k - \alpha_k g_k \in \mathbb{R}^n$ avec $g_k \in \partial f(x_k)$ $\alpha_k > 0$

$$\begin{aligned}\|z_{k+1} - x^*\|^2 &= \|x_k - \alpha_k g_k - x^*\|^2 \\ &\leq \|x_k - x^*\|^2 - 2\alpha_k (f(x_k) - f(x^*)) + \alpha_k^2 \|g_k\|^2 \\ \text{car } g_k &\in \partial f(x_k)\end{aligned}$$

$$\begin{aligned}\text{Or } \|x_{k+1} - x^*\|^2 &= \|\Pi_{\mathcal{C}}(z_{k+1}) - \Pi_{\mathcal{C}}(x^*)\|^2 \\ \text{car } x^* \in \mathcal{C} \Rightarrow \Pi_{\mathcal{C}}(x^*) &= x^* \\ \text{par définition de } x_{k+1} &\\ &\leq \|z_{k+1} - x^*\|^2 \text{ car } \Pi_{\mathcal{C}} \text{ 1-lipschitzienne} \\ &\leq \|x_k - x^*\|^2 - 2\alpha_k (f(x_k) - f(x^*)) + \alpha_k^2 \|g_k\|^2\end{aligned}$$

On retrouve les mêmes résultats de convergence que l'algorithme de sous-gradient.

Notamment $\mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ itérations pour atteindre $|f_{\text{best}}^k - f(x^*)| < \varepsilon$

Rem: $\Pi_{\mathcal{C}}(x)$ peut être difficile à calculer en pratique selon ce qu'est \mathcal{C} .

3) Cas particulier : contraintes convexes d'inégalité

$$\begin{cases} \min_{x \in \mathbb{R}^n} f(x) \\ \text{tq } \forall i \in [1, p] \quad f_i(x) \leq 0 \end{cases} \quad \text{avec } f \text{ et } (f_i)_{i \in [1, p]} \text{ convexe sur } \mathbb{R}^n$$

$$\text{En posant } \mathcal{C} = \{x \in \mathbb{R}^n \mid \forall i \in [1, p] \quad f_i(x) \leq 0\}$$

$$\begin{aligned}\Rightarrow \min_{x \in \mathcal{C}} f(x) \text{ avec } \mathcal{C} \text{ convexe :} \\ \forall i \in [1, p] \quad f_i(\lambda x + (1-\lambda)y) &\leq \lambda f_i(x) + (1-\lambda) f_i(y)\end{aligned}$$

par convexité de f_i
 ≤ 0 car $\lambda \in [0, 1]$ et $(x, y) \in \mathcal{C}^2$

Il est possible d'utiliser l'algorithme de sous-gradient projeté, mais $\Pi_{\mathcal{C}}$ peut être difficile à calculer

Q? Autre stratégie?

Respect des contraintes à chaque itération ?

Algo: $x_0 \in \mathbb{R}^n$

Tant que

calculer $g_k \in \mathbb{R}^n$ tq

$$\begin{cases} g_k \in \partial f(x_k) \text{ si } x_k \in \mathcal{C} \\ g_k \in \partial f_i(x_k) \text{ avec } i \in [1, p] \end{cases}$$

$$\text{tq } f_i(x_k) > 0$$

$$x_{k+1} = x_k - \alpha_k g_k$$

Fin Tant que

On pose $f_{best}^k = \min_{j \in [1, k]} \{f(x_j) \text{ avec } x_j \in \mathcal{C}\}$

On suppose de plus que

$$\exists x_p \in \mathbb{R}^n \text{ tq } \forall i \in [1, p] \quad f_i(x_p) < 0$$

et $f(x_p) \neq f(x^*)$ avec x^* une solution de (P)

avec (α_l) tq

$$\begin{cases} \alpha_l > 0 \quad \forall l \in \mathbb{N} \\ \sum \alpha_l \rightarrow +\infty \\ \sum \alpha_l^2 < +\infty \end{cases}$$

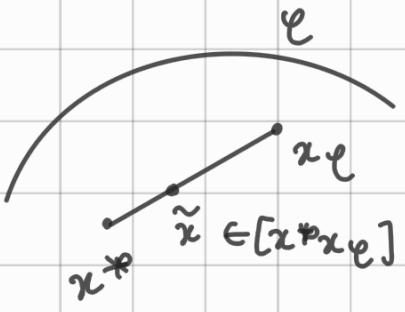
alors $f_{best}^k \xrightarrow[k \rightarrow +\infty]{} f(x^*)$

Supposons le contraire

$$\exists \varepsilon > 0 \text{ tq } \forall N \in \mathbb{N} \quad \exists k \geq N \text{ tq } f_{best}^k \geq f(x^*) + \varepsilon$$

En particulier $f_{best}^N \geq f_{best}^k \geq f(x^*) + \varepsilon$ et ce $\forall N \in \mathbb{N}$

Soit $\lambda \in [0,1]$, on pose $\tilde{x} = (1-\lambda)x^* + \lambda x_\varphi$



Par convexité de f

$$\begin{aligned} f(\tilde{x}) &\leq (1-\lambda)f(x^*) + \lambda f(x_\varphi) \\ &\leq f(x^*) + \lambda(f(x_\varphi) - f(x^*)) \end{aligned}$$

par hypothèse

$$f(x_\varphi) > f(x^*)$$

$$\text{Avec } \lambda = \min\left(1, \frac{\varepsilon}{2(f(x_\varphi) - f(x^*))}\right)$$

$$\text{il vient } f(\tilde{x}) \leq f(x^*) + \frac{\varepsilon}{2}$$

$$\forall i \in \{1, p\} \quad f_i(\tilde{x}) \leq (1-\lambda)f_i(x^*) + \lambda f_i(x_\varphi) \quad \text{par convexité de } f_i$$

$$\text{Or } f_i(x^*) \leq 0 \text{ car } x^* \in \mathcal{C}$$

$$f_i(x_\varphi) > 0 \quad \text{par déf de } x_\varphi$$

$$f_i(\tilde{x}) \leq \lambda f_i(x_\varphi)$$

$$\leq \lambda \max_{j \in \{1, p\}} f_j(x_\varphi)$$

$$\leq -\mu$$

$$\text{avec } \mu = \lambda \max_{j \in \{1, p\}} f_j(x_\varphi) > 0$$

$$\text{d'où } \exists (\tilde{x}, \mu) \in \mathcal{C} \times \mathbb{R}_+^* \text{ tq}$$

$$\begin{cases} f(\tilde{x}) \leq f(x^*) + \frac{\varepsilon}{2} \\ f_i(\tilde{x}) \leq -\mu \quad \forall i \in \{1, p\} \end{cases}$$

$\forall k \geq 1 \in \mathbb{N}$

$$\begin{aligned}\|x_{k+1} - \tilde{x}\|^2 &= \|x_k - \alpha_k g_k - \tilde{x}\|^2 \\ &= \|x_k - \tilde{x}\|^2 - 2\alpha_k g_k^T (x_k - \tilde{x}) + \alpha_k^2 \|g_k\|^2\end{aligned}$$

1^{er} cas: $x_k \in \mathcal{C}$ alors $g_k \in \partial f(x_k)$

$$\text{et } \|x_{k+1} - \tilde{x}\|^2 \leq \|x_k - \tilde{x}\|^2 - 2\alpha_k (f(x_k) - f(\tilde{x})) + \alpha_k^2 \|g_k\|^2$$

Or $x_k \in \mathcal{C} \Rightarrow f(x_k) \geq f_{\text{best}}^k$

$$\geq f(x^*) + \varepsilon \quad \text{par hypothèse}$$

$$\text{de plus } f(\tilde{x}) \leq f(x^*) + \frac{\varepsilon}{2}$$

$$\Rightarrow \|x_{k+1} - \tilde{x}\|^2 \leq \|x_k - \tilde{x}\|^2 - \varepsilon \alpha_k + \alpha_k^2 \|g_k\|^2$$

2^e cas: $\exists i \in \{1, p\}$ tq $f_i(x_k) > 0$
alors $g_k \in \partial f_i(x_k)$

$$\text{et } \|x_{k+1} - \tilde{x}\|^2 \leq \|x_k - \tilde{x}\|^2 - 2\alpha_k (f_i(x_k) - f_i(\tilde{x})) + \alpha_k^2 \|g_k\|^2$$

Or $f_i(x_k) > 0$ et $f_i(\tilde{x}) \leq -\mu$

$$\Rightarrow \|x_{k+1} - \tilde{x}\|^2 \leq \|x_k - \tilde{x}\|^2 - 2\mu \alpha_k + \alpha_k^2 \|g_k\|^2$$

En posant $\delta = \min(2\mu, \varepsilon) > 0$

alors $\forall x_k \in \mathbb{R}^n$

$$\|x_{k+1} - \tilde{x}\|^2 \leq \|x_k - \tilde{x}\|^2 - \delta \alpha_k + \alpha_k^2 \|g_k\|^2$$

Pour récurrence $\|x_{k+1} - \tilde{x}\|^2 \leq \|x_k - \tilde{x}\|^2 - \delta \sum_{l=1}^k \alpha_l + \sum_{l=1}^k \alpha_l^2 \|g_l\|^2$

Avec la même hypothèse que pour l'algorithme du cours-gradient

$$\exists \alpha > 0 \text{ tq } \forall l \in \mathbb{N} \quad \|g_l\| \leq \alpha$$

$$\begin{aligned} \sum_{l=1}^k \alpha_l &\leq \frac{\|x_1 - \tilde{x}\|^2 + \alpha^2 \sum_{l=1}^k \alpha_l^2}{\delta} \\ &\leq \frac{\|x_1 - \tilde{x}\|^2 + \alpha^2 \sum_{l=1}^{+\infty} \alpha_l^2}{\delta} \end{aligned}$$

car $\alpha_l > 0 \quad \forall l \in \mathbb{N} \quad \sum \alpha_l^2 < +\infty$

à la limite $k \rightarrow +\infty$

$$+\infty \leq \frac{\|x_1 - \tilde{x}\|^2 + \alpha^2 \sum_{l=1}^{+\infty} \alpha_l^2}{\delta}$$

d'où contradiction

$$\text{d'où } f_{\text{best}}^k \rightarrow f(x^*)$$

IV. Méthodes proximales

1) Fonction proximale

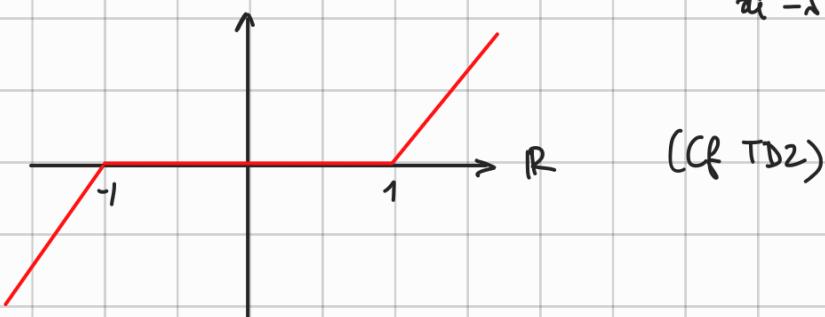
Soit $h : \mathbb{R}^n \rightarrow \mathbb{R}$ convexe. On définit la fonction proximale de h , notée prox_h , par

$$\forall x \in \mathbb{R}^n \quad \text{prox}_h(x) = \underset{u \in \mathbb{R}^n}{\operatorname{argmin}} (h(u) + \frac{1}{2} \|u - x\|_2^2)$$

ex: i) $h = 0$ alors $\text{prox}_h(x) = x \quad \forall x \in \mathbb{R}^n$

ii) Soit P convexe de \mathbb{R}^n soit $h : \mathbb{R}^n \rightarrow \mathbb{R}$
 $\begin{cases} +\infty \text{ si } x \notin P \\ 1 \text{ sinon} \end{cases}$ alors $\text{prox}_h(x) = \Pi_P(x)$

iii) $\forall x \in \mathbb{R}^n \quad h(x) = \lambda \|x\|_1$ avec $\lambda > 0$ prox_h est appelée "seuillage doux", et est
définie par: $\forall i \in [1, n] \quad [\text{prox}_h(x)]_i = \begin{cases} x_i + \lambda & \text{si } x_i < -\lambda \\ 0 & \text{si } |x_i| \leq \lambda \\ x_i - \lambda & \text{si } x_i > \lambda \end{cases}$



2) Méthode du gradient proximal

On s'intéresse au problème d'optimisation (P) $\min_{x \in \mathbb{R}^n} f(x) = g(x) + h(x)$
 avec g convexe dérivée sur \mathbb{R}^n et h convexe, potentiellement non-lisse (mais telle que $\text{prox}_h(x)$ est facilement calculable)

Algo: $x_0 \in \mathbb{R}^n$ Tant que itération de descente de gradient

$$x_{p+1} = \text{prox}_{\alpha_p h}(x_p - \alpha_p \nabla g(x_p))$$

Fin Tant que

et (α_p) obtenue depuis : i) $\forall p \in \mathbb{N} \quad \alpha_p = \alpha > 0$ (pas constraint)
 ii) Recherche linéaire

ex: i) $h=0 \quad x_{p+1} = x_p - \alpha_p \nabla g(x_p) \Rightarrow$ méthode de descente de gradient.
 ii) $h(x) = \begin{cases} +\infty & \text{si } x \notin C \\ 1 & \text{sinon} \end{cases}$ avec C convexe, fermé $\neq \emptyset$ de \mathbb{R}^n

$x_{p+1} = \Pi_C(x_p - \alpha_p \nabla g(x_p)) \Rightarrow$ méthode du gradient projeté
 iii) $h(x) = \lambda \|x\| \Rightarrow$ "seuillage doux" pour minimiser $f(x) = g(x) + \lambda \|x\|$,

Renv: i) $x_{p+1} = \arg \min_{u \in \mathbb{R}^n} (\alpha_p h(u) + \frac{1}{2} \|u - x_p + \alpha_p \nabla g(x_p)\|_2^2)$

$$= \arg \min_{u \in \mathbb{R}^n} (h(u) + \frac{1}{2\alpha_p} [\|u - x_p\|^2 + 2\alpha_p \nabla g(x_p)^T (u - x_p) + \alpha_p^2 \|\nabla g(x_p)\|_2^2])$$

$$= \arg \min_{u \in \mathbb{R}^n} (h(u) + g(x_p) + \nabla g(x_p)^T (u - x_p) + \frac{1}{2\alpha_p} \|u - x_p\|_2^2 + \frac{\alpha_p}{2} \|\nabla g(x_p)\|_2^2)$$

↑ ne change pas le min mais seulement sa valeur

$$= \arg \min_{u \in \mathbb{R}^n} (h(u) + g(x_p) + \nabla g(x_p)^T (u - x_p) + \frac{1}{2\alpha_p} \|u - x_p\|_2^2)$$

modèle quadratique "dégénéré" de g en x_p

$$\begin{aligned} \text{ii)} \quad u = \text{prox}_h(x) &\Leftrightarrow 0 \in \partial \psi(u) \quad \text{avec } \psi(u) = h(u) + \frac{1}{2} \|u - x\|_2^2 \\ &\Leftrightarrow 0 \in \partial h(u) + \{u - x\} \\ &\Leftrightarrow x - u \in \partial h(u) \end{aligned}$$

iii) la méthode du gradient proximal peut se réécrire

$$x_{p+1} = x_p - \alpha_p G_{\alpha_p}(x_p) \text{ avec } G_\alpha(x) = \frac{1}{\alpha} [x - \text{prox}_{\alpha h}(x - \alpha \nabla g(x))]$$

$$\text{En effet, } x_{p+1} - \alpha_p G_{\alpha_p}(x_p) = \text{prox}_{\alpha_p h}(x_p - \alpha_p \nabla g(x_p))$$

$$\text{D'après ii)} \quad x_p - \alpha_p \nabla g(x_p) - x_p + \alpha_p G_{\alpha_p}(x_p) \in \partial \alpha_p h(x_p - \alpha_p G_{\alpha_p}(x_p))$$

$$\Leftrightarrow \alpha_p [G_{\alpha_p}(x_p) - \nabla g(x_p)] \in \partial \alpha_p h(x_p - \alpha_p G_{\alpha_p}(x_p))$$

$$\Leftrightarrow [G_{\alpha_p}(x_p) - \nabla g(x_p)] \in \partial h(x_p - \alpha_p G_{\alpha_p}(x_p))$$

$$\Leftrightarrow G_{\alpha_p}(x_p) \in \partial h(x_p - \alpha_p h(x_p)) + \{\nabla g(x_p)\}$$

$$\text{De plus, } G_{\alpha_p}(x_p) = 0 \Leftrightarrow 0 \in \underbrace{\partial h(x_p - \alpha_p h(x_p)) + \{\nabla g(x_p)\}}_{\partial f(x_p)}$$

$$\text{Ou } f(x) = g(x) + h(x)$$

avec g dérivable convexe sur \mathbb{R}^n

$\Rightarrow x_p$ minimum de f .

D'où tout point fixe de la suite des itérés du gradient proximal est un minimum de f .

3) Recherche linéaire (choix des (α_p)) et convergence de l'algorithme

Algo: Recherche linéaire : backtracking + condition d'arrêt modifiée

Soient $\alpha_0 > 0$, $\beta \in]0; 1[$

Tant que

$$\alpha_{l+1} = \beta \alpha_l$$

critère d'arrêt STOP si

$$\begin{aligned} g(x_p - \alpha_l G_{\alpha_l}(x_p)) &\leq g(x_p) - \alpha_l G_{\alpha_l}(x_p)^T \nabla g(x_p) \\ &\quad + \frac{\alpha_l}{2} \|G_{\alpha_l}(x_p)\|_2^2 \end{aligned}$$

Fin tant que

Rem: $G_{\alpha_l}(x_p)$ à calculer pour toute nouvelle valeur de α_l

prop On suppose que ∇g est L -lipschitzienne avec $L > 0$:

$$\forall (x, y) \in (\mathbb{R}^n)^2 \quad \|\nabla g(x) - \nabla g(y)\|_2^2 \leq L \|x - y\|_2$$

Alors l'algorithme de recherche linéaire s'arrête sur $\alpha_p \geq \min(\alpha_0, \frac{\beta}{L}) := \alpha_{\min}$

preuve: ∇g L-lipschitzien $\Rightarrow \forall (x, y) \in (\mathbb{R}^n)^2$

$$g(y) \leq g(x) + \nabla g(x)^T(y-x) + \frac{L}{2} \|y-x\|_2^2 \quad (\text{admis})$$

$$\text{D'où } g(x_p - \alpha_p G_{\alpha_p}(x_p)) \leq g(x_p) - \alpha_p \nabla g(x_p)^T G_{\alpha_p}(x_p) + \frac{L}{2} \alpha_p^2 \|G_{\alpha_p}(x_p)\|_2^2$$

La condition est valide $\forall \alpha_p \in [0; \frac{1}{L}]$

\Rightarrow à l'arrêt de la recherche linéaire $\alpha_p \geq \alpha_{\min}$

(suite strictement décroissante qui tend vers 0)

prop: On suppose ∇g L-lipschitzien

À l'arrêt de la recherche linéaire ($\rightarrow (\alpha_p, G_{\alpha_p}(x_p))$)

$$\forall z \in \mathbb{R}^n \quad f(x_p - \alpha_p G_{\alpha_p}(x_p)) \leq f(z) + G_{\alpha_p}(x_p)^T(x_p - z) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2$$

preuve: Par définition du critère d'arrêt de la recherche linéaire :

$$\begin{aligned} g(x_p - \alpha_p G_{\alpha_p}(x_p)) &\leq g(x_p) - \alpha_p G_{\alpha_p}(x_p)^T \nabla g(x_p) + \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2 \\ &\leq g(x_p) - \alpha_p G_{\alpha_p}(x_p)^T (G_{\alpha_p}(x_p) - \nabla g(x_p)) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2 \end{aligned}$$

D'après Rem iii) $G_{\alpha_p}(x_p) - \nabla g(x_p) \in \partial h(x_p - \alpha_p G_{\alpha_p}(x_p))$

$$\text{d'où } \forall z \in \mathbb{R}^n \quad h(z) \geq [G_{\alpha_p}(x_p) - \nabla g(x_p)]^T (z - x_p + \alpha_p G_{\alpha_p}(x_p))$$

$$+ h(x_p - \alpha_p G_{\alpha_p}(x_p))$$

$$\text{De plus } g(x_p - \alpha_p G_{\alpha_p}(x_p)) + h(x_p - \alpha_p G_{\alpha_p}(x_p))$$

$$\begin{aligned} &\leq g(x_p) + h(x_p - \alpha_p G_{\alpha_p}(x_p)) + \alpha_p G_{\alpha_p}(x_p)^T (G_{\alpha_p}(x_p) - \nabla g(x_p)) \\ &\quad - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2 \end{aligned}$$

$$\text{Or } h(x_p - \alpha_p G_{\alpha_p}(x_p)) \leq h(z) + [G_{\alpha_p}(x_p) - \nabla g(x_p)]^T (x_p - \alpha_p G_{\alpha_p}(x_p) - z)$$

$$\begin{aligned} \Rightarrow f(x_p - \alpha_p G_{\alpha_p}(x_p)) &\leq g(x_p) + h(z) + \alpha_p G_{\alpha_p}(x_p)^T (h(x_p)(x_p) - \nabla g(x_p)) \\ &\quad + [G_{\alpha_p}(x_p) - \nabla g(x_p)]^T (x_p - \alpha_p G_{\alpha_p}(x_p) - z) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2 \end{aligned}$$

$$f(x_p - \alpha_p G_{\alpha_p}(x_p)) \leq g(x_p) + h(z) + [G_{\alpha_p}(x_p) - \nabla g(x_p)]^T (x_p - z) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2$$

Or g convexe et dérivable sur \mathbb{R}^n

$$\text{D'où } \forall z \in \mathbb{R}^n \quad g(z) \geq \nabla g(x_p)^T (z - x_p) + g(x_p)$$

$$\Rightarrow g(x_p) \leq g(z) + \nabla g(x_p)^T (x_p - z)$$

$$\text{Finalement } f(x_p - \alpha_p G_{\alpha_p}(x_p)) \leq g(z) + h(z) + \nabla g(x_p)^T (x_p - z)$$

$$+ [G_{\alpha_p}(x_p) - \nabla g(x_p)]^T [x_p - z] - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2$$

$$\Rightarrow f(x_p - \alpha_p G_{\alpha_p}(x_p)) \leq f(z) + G_{\alpha_p}(x_p)^T (x_p - z) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2 \quad \forall z \in \mathbb{R}^n$$

$$\text{prox}_h(x) = \arg \min_{u \in \mathbb{R}^n} (h(u) + \frac{1}{2} \|u - x\|_2^2)$$

De plus, $G_{\alpha_p}(x_p) = 0 \Leftrightarrow x_p$ minimum de f pour \mathbb{R}^n

convergence: On suppose ∇g est L -lipschitzien

On suppose également que $\forall p \in \mathbb{N}$ $\alpha_p = \frac{1}{L}$ ou α_p est obtenue depuis l'algorithme de recherche linéaire.

$$\forall z \in \mathbb{R}^n \quad f(x_{p+1}) \leq f(z) + G_{\alpha_p}(x_p)^T (x_p - z) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2$$

$$\text{Avec } z = x_p \quad f(x_{p+1}) \leq f(x_p) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2$$

Si x_p n'est pas un minimum de f $G_{\alpha_p}(x_p) \neq 0 \Rightarrow f(x_{p+1}) < f(x_p)$
 \Rightarrow méthode de descente

Avec $z = x^*$

$$f(x_{p+1}) \leq f(x^*) + G_{\alpha_p}(x_p)^T (x_p - x^*) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2$$

$$\Rightarrow 0 \leq f(x_{p+1}) - f(x^*) \leq G_{\alpha_p}(x_p)^T (x_p - x^*) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2$$

$$\text{or } \|x_p - x^*\|_2^2 - \|x_{p+1} - x^*\|_2^2 = \|x_p - x^*\|_2^2 - \|x_p - \alpha_p G_{\alpha_p}(x_p) - x^*\|_2^2$$

$$= 2\alpha_p G_{\alpha_p}(x_p)^T (x_p - x^*) + \alpha_p^2 \|G_{\alpha_p}(x_p)\|_2^2$$

$$= 2\alpha_p [G_{\alpha_p}(x_p)^T (x_p - x^*) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2]$$

$$\Rightarrow G_{\alpha_p}(x_p)^T (x_p - x^*) - \frac{\alpha_p}{2} \|G_{\alpha_p}(x_p)\|_2^2 = \frac{1}{2\alpha_p} (\|x_p - x^*\|_2^2 - \|x_{p+1} - x^*\|_2^2)$$

$$\text{FT } 0 \leq f(x_{p+1}) - f(x^*) \leq \frac{1}{2\alpha_p} (\|x_p - x^*\|_2^2 - \|x_{p+1} - x^*\|_2^2) \quad (\star)$$

$$\text{D'où } 0 \leq \sum_{l=0}^P (f(x_{l+1}) - f(x^*)) \leq \frac{1}{2} \sum_{l=0}^P \frac{1}{\alpha_l} (\|x_l - x^*\|_2^2 - \|x_{l+1} - x^*\|_2^2)$$

(x^* minimum de f sur $\mathbb{R}^n \Leftrightarrow \forall z \in \mathbb{R}^n f(z) \geq f(x^*)$)

En posant $f_{best}^P = \min_{l \in [0, P]} f(x_l)$

$$\Rightarrow 0 \leq p (f_{best}^P - f(x^*)) \leq \frac{1}{2} \sum_{l=0}^{P-1} \frac{1}{\alpha_l} (\|x_l - x^*\|_2^2 - \|x_{l+1} - x^*\|_2^2)$$

En posant $\alpha^* = \begin{cases} \frac{1}{l} & \text{si stratégie de pas constant} \\ \alpha_{\min} & \text{si recherche linéaire} \end{cases}$

$$\Rightarrow 0 \leq p (f_{best}^P - f(x^*)) \leq \frac{1}{2\alpha^*} \underbrace{\sum_{l=0}^{P-1} (\|x_l - x^*\|_2^2 - \|x_{l+1} - x^*\|_2^2)}_{\geq 0 \text{ par } (\star)} \\ = \|x_0 - x^*\|_2^2 - \|x_p - x^*\|_2^2 \\ \leq \|x_0 - x^*\|_2^2 \geq 0$$

Soit $A \geq \|x_0 - x^*\|_2$

$$\text{Alors } 0 \leq f_{best}^P - f(x^*) \leq \frac{R^2}{2\alpha^*} \frac{1}{P} \xrightarrow[P \rightarrow +\infty]{} 0 \quad \text{d'où } f_{best}^P \xrightarrow{} f(x^*)$$

On atteint $0 \leq f_{best}^P - f(x^*) \leq \varepsilon$ avec $\varepsilon > 0$

au plus tard si $P \geq \left(\frac{2\alpha^*}{R^2}\right) \frac{1}{\varepsilon}$

$\Rightarrow O(\frac{1}{\varepsilon})$ itérations pour atteindre la précision ε sur la valeur de $f(x^*)$

4) Méthode accélérée du gradient proximal

sous les mêmes hypothèses que la méthode du gradient proximal,

algorithme FISTA pour Fast Iterative Shrinkage-Thresholding algorithm.

$$x_0 \in \mathbb{R}^n$$

$$y_0 = x_0$$

Tant que

$$x_p = \text{prox}_{\alpha_p h}(y_{p-1} - \alpha_p \nabla g(y_{p-1}))$$

$$y_p = x_p + \frac{p-1}{p+2} (x_p - x_{p-1})$$

Fin tant que

Algo de recherche linéaire:

$$t_0 = \alpha_{p-1}, \beta \in [0; 1[$$

Tant que

$$t_l = \beta t_{l-1}$$

$$\text{Arrêt si } g(y_{p-1} - t_l \nabla g(y_{p-1})) \leq g(y_{p-1}) - t_l G_{\alpha_p}(y_{p-1})^T \nabla g(y_{p-1}) + \frac{t_l}{2} \|G_{\alpha_p}(y_{p-1})\|_2^2$$

Fin tant que

$$\alpha_p = t_l$$

Pour $\alpha_p = \frac{1}{L}$ on isen de la recherche linéaire

$$0 \leq f_{\text{best}}^P - f(x^*) \leq \varepsilon \text{ avec } \varepsilon > 0$$

atteint en au plus $O(\frac{1}{\sqrt{\varepsilon}})$ itérations